

优化算法实现报告

Author: lvwenlong_lambda@qq.com

Last Modified: 2016/06/20-10:04:27

Contents

project 简介	1
基本数据结构	2
一维优化算法	2
Fibonacci 法	3
黄金分割法	4
外推法	5
不精确线搜索	7
多维函数优化	7
梯度下降法	9
共轭梯度法	10
牛顿法	12
拟牛顿法: BFGS法与DFP法	12
单纯形法	15
鲍威尔法	17
Benchmark	19

project 简介

这个 project 是杜建洪老师课程中介绍的优化算法的 c++ 实现。实现了如下算法：

- 各种一维查找算法，如斐波那契法、黄金分割法、外推法
- 基于 strong wolfe condition 的不精确线搜索方法
- 梯度下降法 (Gradient Descent Method)
- 共轭梯度法 (Conjugate Gradient Method)
- 牛顿法 (Newton Method)
- 拟牛顿法 (Quasi Newton Method)，包括 BFGS 算法与 DFP 算法。
- 单纯形法 (Simplex Method)
- 鲍威尔法 (Powell Method)

这个 project 使用 **CMake** 来 build，使用者需要在系统中事先安装 CMake，程序是在 ubuntu 操作系统下编写与测试，在 g++ 4.8 版本编译器与 clang 3.7 中编译测试成功。CMake 也可以生成 Windows 下 Visual Studio 的工程文件，具体的使用请参考 CMake 手册。

使用者可以使用如下方式来编译：

```
cd /path/to/this/project/src
mkdir out_build
cd out_build
cmake ..
make
cd ..
```

要安装 CMake，在 ubuntu 系统中，可以直接 `sudo apt-get install cmake` 来执行，在 Windows 系统中，可以去网站下载安装包。在其他系统中，可以查看 CMake 网站相关帮助。

在运行 `cmake ..` 命令时，可以通过下列的两个命令行选项来控制程序的行为：

- `-DWRITE_LOG=ON/OFF`，是否在优化时对每个点进行记录，如果为 `OFF` 则只记录最终的最优点
- `-DDEBUG_OPTIMIZER=ON/OFF`，是否开启debug模式，如果为 `ON`，则会使用统一的随机数发生器种子，这样保证每次运行，都得到相同的结果。

许多算法都需要矩阵运算，在 `project` 中，矩阵运算调用 `Eigen` 实现

基本数据结构

这个 `project` 关注的重点在算法运行的迭代次数。因此，并没对算法运行时采用的数据结构进行优化。

用来表示函数输入参数、函数返回结果、以及待优化函数的数据类型定义如下：

```
// Input parameter for objective function
typedef std::vector<double> Paras;
// Result evaluated by objective function
class Solution { // Para evaluated result class (partial) sort
    Paras _solution;
    std::vector<double> _violation; // sum of constraint violation
    double _fom;

public:
    Solution(const Paras& s, const std::vector<double>& cv, double fom) noexcept;
    Solution() =delete;
    double fom() const noexcept;
    double sum_violation() const noexcept;
    const std::vector<double>& violations() const noexcept;
    const Paras& solution() const noexcept;
    Solution& operator=(const Solution&) =default;
    bool operator<(const Solution& s) const noexcept
    {
        return _fom < s.fom();
    }
    bool operator<=(const Solution& s) const noexcept
    {
        return _fom <= s.fom();
    }
};
// type signature of objective function
typedef std::function<Solution(const Paras&)> ObjFunc;
```

使用 `std::vector<double>` 来表示待优化函数的输入参数，并将其 `typedef` 为 `Paras`。

将输入参数、目标函数的值 `fom`，以及约束 `violation` 打包成一个 `class Solution`，这样会带来额外的拷贝开销，但好处是编程时更加方便，比如，可以很方便的对一组函数的解进行排序，选出最好或者最差的解，如果把输入参数跟目标函数输出分开存储，则如果要对目标函数的解进行排序，则需要额外处理输入参数与目标函数输出的同步问题。

对于目标函数的表示，我采用了 `c++11` 中函数式编程的特性。在 `c++11` 中，可以用 `lambda expression` 来表示一个函数，这样表示的函数可以作为数据处理，可以作为另一个函数的输入参数，也可以作为一个函数的返回值。在这个 `project` 中，目标函数表示为一个输入为 `const Paras&`，输出类型为 `Solution` 的函数。这个函数由用户定义，并作为 `optimizer` 的构造函数的一个参数。

一维优化算法

一维函数优化是优化算法的基本，即使是多元函数，在确定了下一步搜索方向之后，也往往在搜索方向上进行线搜索（`line search`），在这个 `project` 中，实现了 `Fibonacci` 法，黄金分割法和外推这三个优化算法。

首先定义一维函数优化的基类:

```
class Optimizer1D
{
    protected:
        ObjFunc _func;

    public:
        Optimizer1D(ObjFunc func) noexcept : _func(func) {}
        virtual Solution optimize() noexcept = 0;
};
```

Optimizer1D 的构造函数接受一个 ObjFunc 类型, ObjFunc 即上一节介绍过的表示目标函数的类型, 这里的目标函数必须是一维函数, 否则, 程序可能会出错。

Optimizer1D::optimize() 是一个纯虚类, 所有继承 Optimizer1D 类的派生类都需要实现这个方法, 具体的一维优化算法就实现在这里。

Fibonacci 法

Fibonacci 法的类型声明如下:

```
class FibOptimizer : public Optimizer1D
{
    const double _lb;
    const double _ub;
    const size_t _iter;

    public:
        FibOptimizer(ObjFunc f, double lb, double ub, size_t iter) noexcept;
        Solution optimize() noexcept;
        ~FibOptimizer() {}
};
```

Fibonacci 法需要提供一个一维目标函数, 同时, 需要提供搜索的下界与上界, Fibonacci 最终的精度随迭代次数指数下降, 因此还需要提供一个迭代次数, 设置迭代次数默认为 16。

Fibonacci 的基本思路是, 希望在区间 $[a_1, a_2]$ 内寻找函数 f 的最小值, 则在 $[a_1, a_2]$ 内找两个点 a_3 与 a_4 , 分别计算 $y_3 = f(a_3)$ 与 $y_4 = f(a_4)$, 比较 y_3 与 y_4 的值, 若 $y_3 < y_4$, 则说明最小值在 $[a_1, a_4]$ 区间内, 若 $y_3 > y_4$, 则说明最小值在 $[a_3, a_2]$ 区间内, 然后依此递归。

Fibonacci 法靠 Fibonacci 数列来确定 a_3 与 a_4 的值, 因为迭代次数 $iter$ 已经确定, 因此可以事先计算出从 0 到 $iter$ 的 Fibonacci 数列, 对于第 i 次迭代 (从 0 开始), 计算 $r = \frac{F_{iter-1-i}}{F_{iter-i}}$, 然后, 令 $a_3 = a_2 - r(a_2 - a_1)$, 令 $a_4 = a_1 + r(a_2 - a_1)$ 。

Fibonacci 法实现代码如下:

```
Solution FibOptimizer::optimize() noexcept
{
    // 1-D function
    double a1 = _lb;
    double a2 = _ub;
    if (a1 > a2)
    {
        cerr << "Range error" << endl;
        exit(EXIT_FAILURE);
    }
    vector<double> fib_list{1, 1};
```

```

if (_iter > 2)
{
    for (size_t i = 2; i < _iter + 1; ++i)
        fib_list.push_back(fib_list[i - 1] + fib_list[i - 2]);
}
double y1, y2;
for(size_t i = 0; i < _iter - 1; ++i)
{
    const double f1 = fib_list[_iter - 1 - i];
    const double f2 = fib_list[_iter - i];
    const double rate = f1 / f2;
    const double a3 = a2 - rate * (a2 - a1);
    const double a4 = a1 + rate * (a2 - a1);
    const double y3 = _func({a3}).fom();
    const double y4 = _func({a4}).fom();
    if (y3 < y4)
    {
        a2 = a4;
        y2 = y4;
    }
    else
    {
        a1 = a3;
        y1 = y3;
    }
}
return _func({a1});
}

```

黄金分割法

黄金分割法的类型声明如下，其类型声明以与 Fibonacci 法一致。

```

class GoldenSelection : public Optimizer1D
{
    const double _lb;
    const double _ub;
    const size_t _iter;

public:
    GoldenSelection(ObjFunc f,
        double lb,
        double ub,
        size_t iter = 16) noexcept;
    Solution optimize() noexcept;
    ~GoldenSelection() {}
};

```

黄金分割法的优化算法实现如下，它的思路与 Fibonacci 法一致，不同的是它使用黄金分割数 0.618 作为固定的区间收缩比例。

```

Solution GoldenSelection::optimize() noexcept
{
    // 1-D function
    // function should be convex function
    double a1 = _lb;

```

```

double a2 = _ub;
if (a1 > a2)
{
    cerr << "Range error" << endl;
    exit(EXIT_FAILURE);
}

const double rate = (sqrt(5) - 1) / 2;
double y1, y2;
for (size_t i = _iter - 1; i > 0; --i)
{
    const double interv_len = a2 - a1;
    const double a3 = a2 - rate * interv_len;
    const double a4 = a1 + rate * interv_len;
    if (a3 == a4)
        break;
    else
    {
        assert(a3 < a4);
        const double y3 = _func({a3}).fom();
        const double y4 = _func({a4}).fom();
        if (y3 < y4)
        {
            a2 = a4;
            y2 = y4;
        }
        else
        {
            a1 = a3;
            y1 = y3;
        }
    }
}
return y1 < y2 ? _func({a1}) : _func({a2});
}

```

外推法

黄金分割法与 Fibonacci 法都需要事先知道最优点的范围，而外推法则可以适用于最优范围不知道的情况，它先寻找一个最优点的范围，然后再去调用其他优化算法，比如黄金分隔法或二次插值法在找到的范围内进行优化。

下面是外推法的类声明以及算法实现：

```

class Extrapolation : public Optimizer1D
{
    const Paras _init;
    const double _min_len; // min extrapolation step
    const double _max_len; // max extrapolation step
public:
    Extrapolation(ObjFunc f,
        Paras i,
        double min_len,
        double max_len
    ) noexcept;

```

```

    Solution optimize() noexcept;
    ~Extrapolation() {}
};

Solution Extrapolation::optimize() noexcept
{
    // 1-D function
    double step = _min_len;
    double x1 = _init[0];
    double x2 = x1 + step;
    double y1 = _func({x1}).fom();
    double y2 = _func({x2}).fom();

    double lb = x1;
    double ub = x1 + _max_len;
    if (y2 > y1)
    {
        step *= -1;
        ub = x1 - _min_len;
        lb = x1 - _max_len;
        x2 = x1 + step;
        y2 = _func({x2}).fom();
        if (y2 > y1) return _func({x1});
    }
    double factor = 2;
    double x3 = x2 + factor * step;
    double y3 = _func({x3}).fom();
    double xa, xc;
    double ya, yc;
    if (y3 > y2)
    {
        xa = x1;
        xc = x3;
        ya = y1;
        yc = y3;
    }
    else
    {
        while (y3 < y2 && (lb < x3 && x3 < ub))
        {
            factor *= 2;
            x3 += factor * step;
            if (x3 >= ub) x3 = ub;
            if (x3 <= lb) x3 = lb;
            y3 = _func({x3}).fom();
        }
        double xtmp1 = x3 - factor * step;
        double xtmp2 = x3 - (factor / 2) * step;
        double ytmp1 = _func({xtmp1}).fom();
        double ytmp2 = _func({xtmp2}).fom();
        if (ytmp1 < ytmp2)
        {
            xa = x2;
            xc = xtmp2;
        }
    }
}

```

```

        ya = y2;
        yc = ytmp2;
    }
    else
    {
        xa = xtmp1;
        xc = x3;
        ya = ytmp1;
        yc = y3;
    }
}

if (xa > xc)
{
    std::swap(xa, xc);
    std::swap(ya, yc);
}
const double len = xc - xa;
const size_t gso_iter = 2 + (log10(_min_len / len) / log10(0.618));
return GoldenSelection(_func, xa, xc, gso_iter).optimize();
}

```

不精确线搜索

上一节实现的一维优化算法，都是期望找到在搜索方向上的最优点。但是，很多时候，找到严格意义上的最优点，往往需要很多次迭代；而且，因为搜索方向上的最优点并不是多元函数的最优点，在多元函数优化过程中，找到搜索方向上的最优点也没有必要。只要保证步长使得函数在搜索方向上下降足够多就可以了。因此，在实际的多元函数优化中，当需要确定在搜索方向上的步长时，常常并不采用精确的一元函数优化算法，而是规定一个“在搜索方向上足够下降”的标准，然后只要找到满足这样标准的点即可。

Strong wolfe condition 是一个常用的不精确线搜索的判据，其判据如下：

$$\begin{cases} f(x_k + \alpha_k p_k) & \leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k \\ |\nabla f(x_k + \alpha_k p_k)^T p_k| & \leq c_2 |\nabla f_k^T| \end{cases}$$

在上式中， c_1 与 c_2 满足 $0 < c_1 < c_2 < 1$ ，其中，第一个不等式被称作 **sufficient decrease condition**，第二个不等式被称作 **curvature condition**。如果步长满足 sufficient decrease condition，则说明在步长处，函数已经有了足够的下降，而 curvature condition 则是要求函数在搜索方向上的梯度也有足够大的下降，因为很显然，如果在步长处函数的梯度仍然很大，则说明在这个方向上仍有进一步改变步长的余地。

Figure 1 是 strong wolfe condition 的一个例子，对于图中一维函数，只要最终步长选在位于“acceptable”的区间内即可。

本次 project 实现了寻找满足 strong wolfe condition 的搜索步长的算法，其基本思路是，先通过插值与外推的方法，尝试一系列递增的 trial step，找到一个满足 strong wolfe condition 的区间。再在这个区间内，进行二次或三次插值，直到找到满足 strong wolfe condition 的步长。

Strong wolfe condition 不精确线搜索算法代码，可以去 `src/Optimizer/StrongWolfe.cpp` 中查看。

多维函数优化

首先定义了两个基类，MultiDimOptimizer 与 GradientMethod，其中，MultiDimOptimizer 是一切多元函数优化算法的基类，在其中定义了一些辅助性质的成员变量与函数，如函数维度、最大迭代次数，最大与最小步长等。

GradientMethod 是 MultiDimOptimizer 的一个派生类，它是所有基于梯度法的算法的基类，包括梯度下降法、共轭梯度法、牛顿法和拟牛顿法。




Figure 1: Example of wolfe condition

在 GradientMethod 中定义了一些与梯度有关的变量与函数，如求梯度的 GradientMethod::get_gradient，求 Hessian 矩阵的 GradientMethod::hessian，这两个函数都是虚函数，可以被派生类重载。MultiDimOptimizer 中还定义了一些与梯度相关的成员变量，如用数值法求梯度时用到的 _epsilon。以及判定收敛（梯度为零）的最小梯度等。

```
class MultiDimOptimizer
{
protected:
    const size_t      _dim;
    const size_t      _max_iter;
    const double       _min_walk;
    const double       _max_walk;
    const std::string  _func_name;
    const std::string  _algo_name;
    std::ofstream      _log;

    virtual Solution run_func(const Paras&) noexcept;
    virtual Solution run_line_search(
        const Solution& s,
        const Eigen::VectorXd& direction
    ) noexcept;

private:
    ObjFunc      _func;
    StrongWolfe  _line_searcher;
    size_t       _eval_counter;
    size_t       _linesearch_counter;
```



```

public:
    void clear_counter() noexcept
    {
        _eval_counter = 0;
        _linesearch_counter = 0;
    }
    size_t eval_counter() noexcept { return _eval_counter; }
    size_t linesearch_counter() noexcept
    {
        return _linesearch_counter;
    }
    MultiDimOptimizer(
        ObjFunc f,
        size_t d,
        size_t max_iter,
        double min_walk,
        double max_walk,
        std::string func_name,
        std::string algo_name) noexcept;
    virtual ~MultiDimOptimizer(){}
};
class GradientMethod : public MultiDimOptimizer
{
protected:
    const Paras _init;
    const double _epsilon; // use _epsilon to calc gradient
    const double _zero_grad; // threshold for zero gradient

    virtual Eigen::VectorXd get_gradient(const Solution& s) noexcept;
    virtual Eigen::MatrixXd hessian(
        const Solution& point,
        const Eigen::VectorXd& grad
    ) noexcept;

public:
    GradientMethod(
        ObjFunc f,
        size_t d,
        Paras i,
        double epsi,
        double zgrad,
        double minwalk,
        double maxwalk,
        size_t max_iter,
        std::string fname,
        std::string aname) noexcept;
    virtual ~GradientMethod() { if(_log.is_open()) _log.close(); }
};

```

梯度下降法

梯度下降法假定函数在搜索域内总是一阶可导，对一个函数 f ，给定一个初始点 x_k ，梯度 $g_k = \nabla f(x_k)$ ，则搜索方向 $d_k = -g_k$ ，当梯度为零时判定收敛，此时，找到了函数在这个区域的极小值。

梯度下降法算法描述如下：

1. 对初始点 x_k ，求出其梯度 $g_k = \nabla f(x_k)$ ，若 $g_k \leq g_{zero}$ ，或者达到 max_iter ，则判定收敛。
2. 搜索方向 $d_k = -g_k$
3. 在搜索方向上做一维搜索，找出最优步长 $\lambda_k = \arg \min_{\lambda} f(x_k + \lambda d_k)$
4. $x_{k+1} = x_k + \lambda_k d_k$ ，置 $k = k + 1$ ，转 step 1。

梯度下降法实现代码如下：

```
Solution GradientDescent::optimize() noexcept
{
    clear_counter();
    _log << _func_name << endl;

    Solution sol      = run_func(_init);
    VectorXd grad      = get_gradient(sol);
    double grad_norm   = grad.lpNorm<2>();
    double len_walk    = numeric_limits<double>::infinity();
    while (grad_norm    > _zero_grad
           && eval_counter() < _max_iter
           && len_walk    > _min_walk)
    {
        // LOG is a macro used to record evaluated function input
        LOG(sol, grad);
        const Solution new_sol = run_line_search(sol, -1 * grad);
        len_walk = vec_norm(new_sol.solution() - sol.solution());
        sol      = new_sol;
        grad      = get_gradient(sol);
        grad_norm = grad.lpNorm<2>();
    }
    _log << "===== " << endl;
    write_log(sol, grad);
    _log << "len_walk: " << len_walk << endl;
    _log << "eval: " << eval_counter() << endl;
    _log << "line search: " << linesearch_counter() << endl;
    if (eval_counter() >= _max_iter)
        _log << "max iter reached" << endl;
    return sol;
}
```

共轭梯度法

当目标函数在极值点附近的条件数（即 Hessian 矩阵最大特征值与最小特征值之比）过大时，梯度下降法在极值点附近会出现来回折叠现象，导致收敛较慢。共轭梯度法（Conjugate Gradient Method）可以克服这种问题，它选择共轭梯度方向作为搜索方向。

可以证明，如果目标函数在极值点附近是二次的，对于 N 维函数，则只需要 N 次一维查找，就可以找到极值点。当然上面的一维查找指的是精确的一维查找。如果使用不精确一维查找或者问题的阶数高于二阶， N 维问题需要的查找次数会大于 N 。

对于一个 N 维矩阵 A ，如果向量 u, v ，满足 $u^T A v = 0$ ，则这两个向量对于矩阵 A 共轭。 N 维空间中，共有 N 个互相共轭的向量。共轭梯度法第一步以梯度方向为搜索方向，而后每一步的搜索方向都与之前的搜索方向互相共轭，如此搜索 N 步。如果 N 步之后，仍然没有找到极值点。则再以梯度方向为搜索方向，再搜索 N 步。如此循环，直至找到极值点。

共轭梯度法算法描述如下：

1. $k = 1$ ， x_k 为初始点，计算梯度 $g_k = \nabla f(x_k)$ ，若 $g_k \leq g_{zero}$ 或者达到最大迭代次数，则算法终止。否则，选择搜索方向 $d_k = -g_k$
2. 搜索方向上做一维搜索，找到最优步长

- $\lambda_k = \arg \min_{\lambda} f(x_k + \lambda d_k)$
 - $x_{k+1} = x_k + \lambda_k d_k$
3. 计算 x_{k+1} 点的梯度 $g_{k+1} = \nabla f(x_{k+1})$, 计算 d_{k+1} :
- $\beta = \frac{|g_{k+1}|^2}{|g_k|^2}$
 - $d_{k+1} = -g_{k+1} + \beta d_k$
4. $k = k + 1$, 若 $k \leq \dim - 1$, 则转step 2, 否则, 若 $g_k \leq g_{zero}$, 则算法终止, 否则转 step 1。

共轭梯度法的实现代码如下:

```
Solution ConjugateGradient::optimize() noexcept
{
    clear_counter();
    _log << _func_name << endl;

    Solution sol          = run_func(_init);
    VectorXd grad         = get_gradient(sol);
    VectorXd conj_grad    = grad;
    double grad_norm      = grad.lpNorm<2>();
    double len_walk       = numeric_limits<double>::infinity();
    assert(sol.solution().size() == _dim);
    while (grad_norm > _zero_grad    &&
           eval_counter() < _max_iter &&
           len_walk > _min_walk)
    {
        conj_grad = grad;
        for (size_t i = 0; i < _dim; ++i)
        {
            LOG(sol, grad, conj_grad);
            const Solution new_sol = run_line_search(
                sol,
                -1 * conj_grad);
            VectorXd new_grad = get_gradient(new_sol);
            double beta = pow(new_grad.lpNorm<2>()/grad.lpNorm<2>(), 2);

            len_walk = vec_norm(new_sol.solution() - sol.solution());
            sol      = new_sol;
            conj_grad = new_grad + beta * conj_grad;
            grad      = new_grad;
            grad_norm = grad.lpNorm<2>();
            if (!(grad_norm > _zero_grad)) break;
        }
    }
    _log << "=====" << endl;
    write_log(sol, grad, conj_grad);
    _log << "len_walk:    " << len_walk          << endl;
    _log << "eval:         " << eval_counter()       << endl;
    _log << "line search: " << linesearch_counter() << endl;
    if (eval_counter() >= _max_iter)
        _log << "max iter reached" << endl;
    return sol;
}
```

牛顿法

梯度下降法与共轭梯度法都是利用函数的梯度，而牛顿法利用函数的二阶导（Hessian 矩阵），因而能够达到比梯度下降法与共轭梯度法更快的收敛速度。

牛顿法算法描述如下：

1. 对于初始点 x_k ，求出梯度 $g_k = \nabla f(x_k)$ ，若 $g_k \leq g_{zero}$ ，则判定收敛，算法终止。
2. 求出 Hessian 矩阵 H_k ，计算搜索方向 $d_k = -H_k g_k$ 。
3. 在搜索方向上做一维搜索，计算最优步长 $\lambda_k = \arg \min_{\lambda} f(x_k + \lambda d_k)$
4. $x_{k+1} = x_k + \lambda_k d_k$ ，转 step 1。

牛顿法的实现代码如下：

```
Solution Newton::optimize() noexcept
{
    clear_counter();
    _log << "func: " << _func_name << endl;
    Solution sol = run_func(_init);
    VectorXd grad = get_gradient(sol);
    MatrixXd hess = hessian(sol, grad);
    double grad_norm = grad.lpNorm<2>();
    double len_walk = numeric_limits<double>::infinity();
    while (grad_norm > _zero_grad &&
           eval_counter() < _max_iter &&
           len_walk > _min_walk)
    {
        VectorXd direction = -1*hess.colPivHouseholderQr().solve(grad);
        double judge = grad.transpose() * direction;
        double dir = judge < 0 ? 1 : -1;
        LOG(sol, grad, hess);
        direction *= dir;
        Solution new_sol = run_line_search(sol, direction);
        len_walk = vec_norm(new_sol.solution() - sol.solution());
        sol = new_sol;
        grad = get_gradient(sol);
        hess = hessian(sol, grad);
        grad_norm = grad.lpNorm<2>();
    }
    _log << "=====" << endl;
    write_log(sol, grad, hess);
    _log << "len_walk: " << len_walk << endl;
    _log << "iter: " << eval_counter() << endl;
    _log << "line search: " << linesearch_counter() << endl;
    _log << "eigenvalues of hess: " << endl;
    _log << hess.eigenvalues() << endl;
    if (eval_counter() >= _max_iter)
        _log << "max iter reached" << endl;
    return sol;
}
```

拟牛顿法：BFGS法与DFP法

Newton 法是二阶收敛，因此在理论上会比梯度法更快。但是如果目标函数无法直接给出 Hessian 矩阵，则要用有限差分的方法近似 Hessian 矩阵。对于 N 维的问题，其复杂度为 $O(N^2)$ ，当目标函数的维度上升时，求 Hessian 矩阵的代价就会变得不可接受。拟牛顿

法 (Quasi-Newton Method) 通过迭代的方法, 来近似 Hessian 矩阵。常见的拟牛顿法有 DFP 法与 BFGS 法。

在牛顿法迭代过程中, Hessian 矩阵满足如下关系:

$$g_{k+1} - g_k = H_k(x_{k+1} - x_k)$$

记 $y_k = g_{k+1} - g_k$, $\delta_k = x_{k+1} - x_k$, 则:

$$y_k = H_k \delta_k$$

或者:

$$\delta_k = H_k^{-1} y_k$$

上面两式称作**拟牛顿条件**。如果 H_k 是正定的, 则搜索方向 $d_k = -H_k g_k$ 是一个下降方向。

选定初始的正定矩阵 G_0 , 对于空间中点 x_k , 其梯度 g_k

对 DFP 法, G 矩阵如此确定

$$G_{k+1} = G_k + \frac{\delta_k \delta_k^T}{\delta_k^T y_k} - \frac{G_k y_k y_k^T G_k}{y_k^T G_k y_k}$$

对BFGS

$$\begin{cases} \mu_k &= 1 + \frac{y_k^T H_k y_k}{\delta_k^T y_k} \\ G_{k+1} &= G_k + \frac{\mu_k \delta_k \delta_k^T - H_k y_k \delta_k^T - \delta_k y_k^T H_k}{\delta_k^T y_k} \end{cases}$$

搜索方向

$$d_k = -H_k g_k$$

BFGS法的实现代码如下:

```
Solution BFGS::optimize() noexcept
{
    clear_counter();
    _log << "func: " << _func_name << endl;

    Solution sol = run_func(_init);
    VectorXd grad = get_gradient(sol);
    MatrixXd quasi_hess = MatrixXd::Identity(_dim, _dim);
    double grad_norm = grad.lpNorm<2>();
    double len_walk = numeric_limits<double>::infinity();

    while (grad_norm > _zero_grad && eval_counter() < _max_iter &&
           len_walk > _min_walk)
    {
        LOG(sol, grad, quasi_hess);
        const VectorXd direction =
            -1 * (quasi_hess.colPivHouseholderQr().solve(grad));
        const Solution new_sol = run_line_search(sol, direction);
        const VectorXd new_grad = get_gradient(new_sol);
        const vector<double> delta_x =
```

```

        new_sol.solution() - sol.solution();
const VectorXd ev_dg = new_grad - grad;
const Map<const VectorXd> ev_dx(&delta_x[0], _dim, 1);
len_walk = vec_norm(delta_x);
if (len_walk > 0)
{
    quasi_hess +=
        (ev_dg * ev_dg.transpose()) /
        (ev_dg.transpose() * ev_dx) -
        (quasi_hess * ev_dx * ev_dx.transpose() *
         quasi_hess) /
        (ev_dx.transpose() * quasi_hess * ev_dx);

    sol = new_sol;
    grad = new_grad;
    grad_norm = grad.lpNorm<2>();
}
}
_log << "=====" << endl;
write_log(sol, grad, quasi_hess);
_log << "len_walk:    " << len_walk << endl;
_log << "eval:         " << eval_counter() << endl;
_log << "line search: " << linesearch_counter() << endl;

if (eval_counter() >= _max_iter)
    _log << "max iter reached" << endl;
return sol;
}

```

DFP法的实现代码如下:

```

Solution DFP::optimize() noexcept
{
    clear_counter();
    _log << "func: " << _func_name << endl;

    Solution sol = run_func(_init);
    VectorXd grad = get_gradient(sol);
    double grad_norm = grad.lpNorm<2>();
    double len_walk = numeric_limits<double>::infinity();
    MatrixXd quasi_hess_inverse = MatrixXd::Identity(_dim, _dim);

    while (grad_norm > _zero_grad && eval_counter() < _max_iter &&
           len_walk > _min_walk)
    {
        LOG(sol, grad, quasi_hess_inverse);
        VectorXd dvec = -1 * (quasi_hess_inverse * grad);
#ifdef WRITE_LOG
        const double judge = grad.transpose() * dvec;
        _log << "judge: " << judge << endl;
        if (judge > 0) _log << "judge greater than zero" << endl;
#endif
        const Solution new_sol = run_line_search(sol, dvec);
        const VectorXd new_grad = get_gradient(new_sol);
        const vector<double> delta_x =

```

```

        new_sol.solution() - sol.solution();
const VectorXd ev_dg = new_grad - grad;
len_walk = vec_norm(delta_x);
const Map<const VectorXd> ev_dx(&delta_x[0], _dim, 1);
if (len_walk > 0)
{
    quasi_hess_inverse +=
        (ev_dx * ev_dx.transpose()) /
        (ev_dx.transpose() * ev_dg) -
        (quasi_hess_inverse * ev_dg * ev_dg.transpose() *
         quasi_hess_inverse) /
        (ev_dg.transpose() * quasi_hess_inverse * ev_dg);

    sol = new_sol;
    grad = new_grad;
    grad_norm = grad.lpNorm<2>();
}
}
_log << "=====" << endl;
write_log(sol, grad, quasi_hess_inverse);
_log << "len_walk:    " << len_walk << endl;
_log << "eval:         " << eval_counter() << endl;
_log << "line search: " << linesearch_counter() << endl;
if (eval_counter() >= _max_iter)
    _log << "max iter reached" << endl;
return sol;
}

```

单纯形法

算法参数:

- $\alpha > 0$
- $\gamma > 0$
- $0 < \rho \leq 0.5$
- $0 < \sigma \leq 1$

单纯形法算法描述如下:

1. 初始化, 选取 $dim + 1$ 个初始点, 并对其求值, 组成集合 S
2. 若达到最大迭代次数, 或者达到收敛条件, 算法终止。
3. S 中的结果进行排序, 选出最差结果 w , 第二差的结果 s , 以及最好的结果 b 。
4. 算 S 中, 除了 w 以外的其他所有点的中点 c
5. 算反射点 $r = c + \alpha(c - w)$ 。
6. 若 $f(b) \leq f(r) \leq f(s)$, 则用 r 在 S 中更新 w , 并转 step 2
7. 若 $f(r) < f(b)$, 则计算 $e = 2c + \gamma(r - c)$, 并用 $f(e)$ 与 $f(r)$ 中较小的一组解更新 w , 并转 step 2
8. 计算 $cr = c + \rho(w - c)$ 。
9. 若 $f(cr) < f(w)$, 则用 cr 更新 w , 并转 step 2
10. 否则, 更新所有点, 将所有点向 b 靠拢, 对 S 中的任意点 p , 更新 $p = b + \sigma * (p - b)$ 。

单纯形法实现的代码如下:

```

double NelderMead::update_sols(size_t idx,
                               const Solution& new_sol) noexcept
{
    assert(_sols.size() == _dim + 1);

```

```

    assert(idx <= _dim);
    const double walk_len =
        vec_norm(new_sol.solution() - _sols[idx].solution());
    _sols[idx] = new_sol;
    return walk_len;
}
Solution NelderMead::optimize() noexcept
{
    clear_counter();
    _log << _func_name << endl;
    _sols.clear();
    _sols.reserve(_dim + 1);
    for (size_t i = 0; i < _dim + 1; ++i)
        _sols.push_back(run_func(_inits[i]));
    double walk_len = numeric_limits<double>::infinity();
    while (eval_counter() < _max_iter && walk_len > _min_walk)
    {
        // 1. order
        std::sort(_sols.begin(), _sols.end(), std::less<Solution>());
        const Solution& worst = _sols[_dim];
        const Solution& sec_worst = _sols[_dim - 1];
        const Solution& best = _sols[0];

        // 2. centroid calc
        Paras centroid(_dim, 0);
        for (size_t i = 0; i < _dim; ++i)
            centroid = centroid + _sols[i].solution();
        centroid = 1.0 / static_cast<double>(_dim) * centroid;

        // 3. reflection
        Solution reflect = run_func(
            centroid + _alpha * (centroid - worst.solution()));
        LOG(reflect);
        if (best <= reflect && reflect < sec_worst)
        {
            walk_len = update_sols(_dim, reflect);
        }
        else if (reflect < best) // 4. expansion
        {
            Solution expanded = run_func(
                centroid + _gamma * (reflect.solution() - centroid));
            LOG(expanded);
            const Solution& new_sol =
                expanded < reflect ? expanded : reflect;
            walk_len = update_sols(_dim, new_sol);
        }
        else // 5. contract
        {
            assert(!(reflect < sec_worst));
            Solution contracted = run_func(
                centroid + _rho * (worst.solution() - centroid));
            LOG(contracted);
            if (contracted < worst)
            {

```



```

        walk_len = update_sols(_dim, contracted);
    }
    else // 6. shrink
    {
#ifdef WRITE_LOG
        _log << "shrink: " << endl;
#endif

        walk_len = 0;
        for (size_t i = 1; i < _dim + 1; ++i)
        {
            Paras p = best.solution() -
                _sigma * (_sols[i].solution() -
                    best.solution());
            double tmp_walk = update_sols(i, run_func(p));
            walk_len = max(tmp_walk, walk_len);
            LOG(_sols[i]);
        }
    }
}

std::sort(_sols.begin(), _sols.end(), std::less<Solution>());
_log << "=====" << endl;
write_log(_sols[0]);
return _sols[0];
}

```

鲍威尔法

鲍威尔法的实现代码如下:

```

Solution Powell::optimize() noexcept
{
    clear_counter();
    Solution sol = run_func(_init);
    double walk_len = numeric_limits<double>::infinity();

    // initial search directions are axes
    vector<VectorXd> search_direction(_dim, VectorXd(_dim));
    for (size_t i = 0; i < _dim; ++i)
    {
        for (size_t j = 0; j < _dim; ++j)
            search_direction[i][j] = i == j ? 1.0 : 0.0;
    }
    while (eval_counter() < _max_iter && walk_len > _min_walk)
    {
        double max_delta_y = -1 * numeric_limits<double>::infinity();
        size_t max_delta_id;
        Paras backup_point = sol.solution();
        for (size_t i = 0; i < _dim; ++i)
        {
            LOG(sol);
            Solution search_sol =
                run_line_search(sol, search_direction[i]);
            if (sol.fom() - search_sol.fom() > max_delta_y)

```

```

        {
            max_delta_y = sol.fom() - search_sol.fom();
            max_delta_id = i;
        }
        sol = search_sol;
    }
    Paras new_direc = sol.solution() - backup_point;
    VectorXd new_direc_vxd = Map<VectorXd>(&new_direc[0], _dim);
    walk_len = new_direc_vxd.lpNorm<2>();
    search_direction[max_delta_id] = new_direc_vxd;
}
_log << endl
    << "=====" << endl;
write_log(sol);
return sol;
}

```

Benchmark

使用 Rosenbrock 函数来比较不同优化算法的性能。Rosenbrock 函数如下定义：

$$f(x, y) = (1 - x)^2 + 100 * (y - x^2)^2$$

Figure 2 为 Rosenbrock 函数的等高线图，为增强显示效果，图中函数值对 10 取对数，即 $val = \log_{10} f(x, y)$

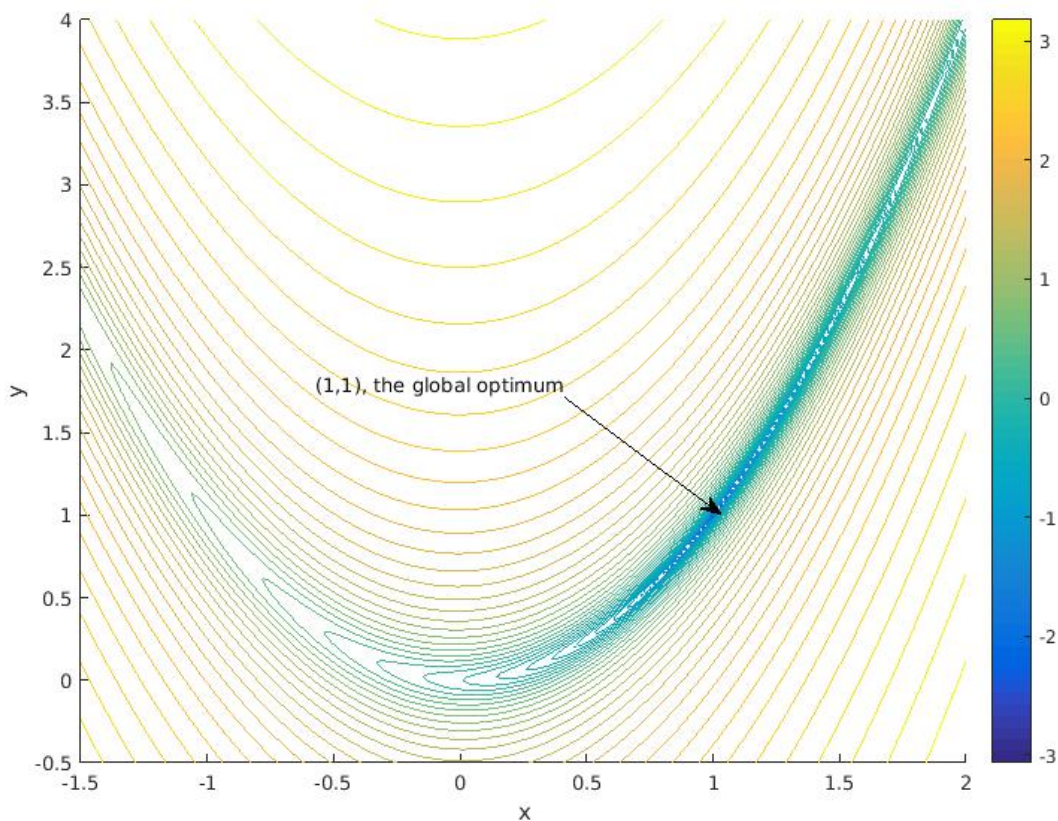


Figure 2: Contour of $\log_{10} f(x, y)$

将 $(-0.76, 2.55)$ 设为初始点（单纯形法除外，单纯形法初始需要 $N+1$ 个点， N 为维度），程序运行结果以及图示见下表以及下图。其中 NumLineSearch 表示程序做一维搜索的次数，即为图上点的数量。而对于梯度法以及鲍威尔法，确定搜索方向后，要找到下一个点，还需要在一维搜索上花费数次函数执行，表中 NumEvaluation 一列表示算法优化过程中实际的函数执行次数。可以看出，梯度下降法表现最差，而单纯形法表现最好。

需要说明的是，表中数据只是不同算法对 Rosenbrock 函数以及 $(-0.76, 2.55)$ 这一个初始点的性能，换一个比较函数，换一个初始点，都可能会有不同的结果。

Table 1: Compare of different algorithms

Algorithm	Fom	NumLineSearch	NumEvaluation
GradientDescent	1.42e-4	639	6516
ConjugateGradient	5.29e-9	48	694
Newton	1.01e-5	11	200

Algorithm	Fom	NumLineSearch	NumEvaluation
DFP	2.68e-6	25	367
BFGS	3.82e-6	29	430
Simplex	2.44e-11	0	170
Powell	9.46e-11	70	739

